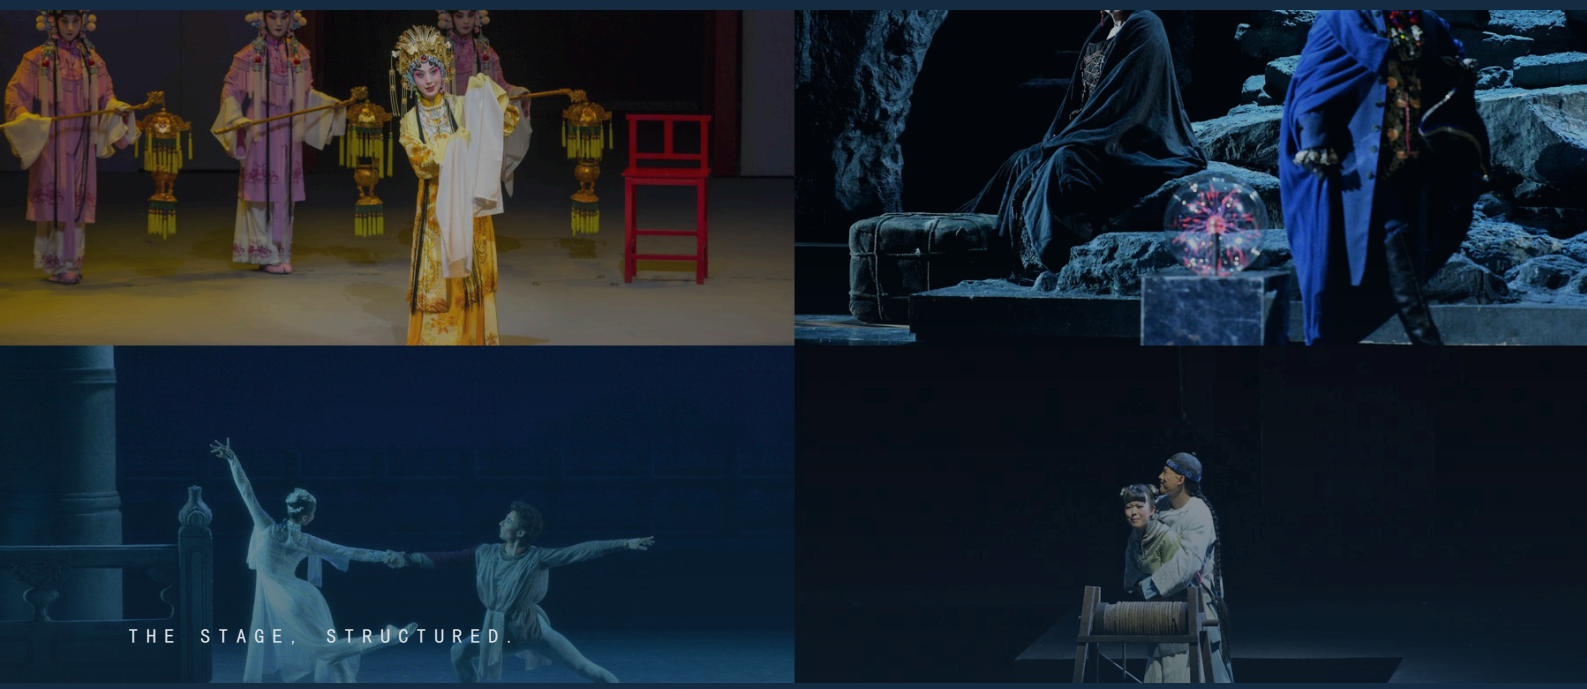
技术评审与研发版

幕间

戏剧照片智能整理系统

功能架构 · 模型原理 · 实验设计 · 结果分析



以可追溯证据连接图像、演员、剧情与人工决定

2026年10月24日

代码基线 ad68c89

4部剧目 · 262张幕次开发样本 · 1095张检测人脸

从舞台影像到可追溯档案

本系统面向戏剧照片中人物众多、舞台光线复杂、文件名信息不一致、剧情资料分散等问题，将人脸识别、图文检索、视觉观察、人工复核与规范归档整合到“幕间”工作台。核心设计是把**模型候选、证据来源和人工决定**作为不同对象保存，使结果能够解释、重跑和恢复。

当前实现已具备可用的照片整理与复核闭环。工程验证覆盖真实GPU任务、服务中断恢复、万条复核队列、原始照片及已整理照片的再次处理。模型研究以4部剧目、262张已确认幕次的开发集图片为核心，比较SigLIP2与本地EmbeddingGemma 2的长文、短块均值及最大值聚合方案。[S02] [S11] [S12] [S15] [S16]

262	76.34%	1,095	200
幕次检索开发样本	Gemma短块均值 R@3 · 25池	可追溯检测人脸	真实流程验证图片

主要技术结论

1. **文本组织会改变检索质量。** 25候选池中，短块均值R@3为SigLIP2 69.85%、Gemma 76.34%；Gemma比同方案SigLIP2净增17张命中。扩展至28候选后，两者变为53.44%和71.76%，说明候选覆盖与竞争必须一起分析。[S02]
2. **工程可靠性已有真实证据。** 292图任务完成1095脸检测和453个旧算法簇，经历取消、部分发布失败和恢复后无项目失败；17项恢复检查通过。[S12]
3. **优化收益取决于测量边界。** 万条合成队列的单条保存及摘要中位耗时由214.706 ms降至1.850 ms；U2历史特征阶段仅1.151倍，未达到既定吞吐门槛。[S13] [S14]
4. **现有材料支持开发比较，尚不支持正式质量通过。** 缺少独立final test、框级身份、双人事实、时序边界和连拍偏好标注。默认保持SigLIP2及legacy分组，U2按用户要求暂停。[S17] [S18]

> 本文的“通过”均指明确的测试或检查范围。模型观察有效、接口成功和文件完整，不等同于身份识别准确、幕次判定可靠或选优质量达标。

阅读路线：第3—11页介绍功能和原理；第12—16页定义实验并展开检索结果；第17—22页分析视觉、分组、性能和真实流程；第23—26页给出质量缺项、复现方法、证据索引和方法参考。报告基于代码提交`ad68c89`，数据截至2026-10-24；未为撰写报告重新进行模型推理。

面向整理人员的一体化工作台

工作台以项目为单位共享照片目录、剧情知识库、人脸库和复核状态，减少在多个工具之间搬运标签与路径。入口`/organize`与`/ui`共用新版工作台，旧版功能仍可从`/legacy`进入。

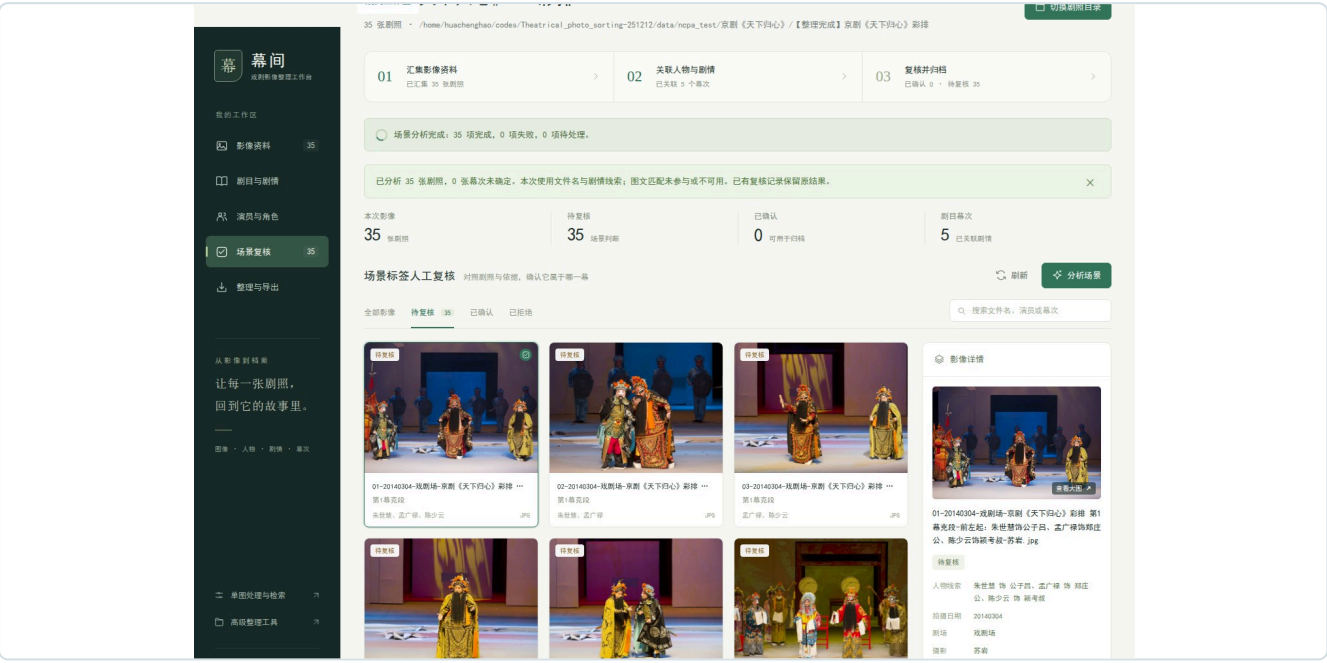


图1 工作台中的剧照浏览、候选场景和复核操作（局部）。来自既有浏览器验收截图；其中脚本决定仅验证交互。

功能域	输入与主要处理	输出及使用方式
影像资料	目录扫描、缩略图、文件名解析、搜索筛选	日期、剧场、剧目、演员线索与图片网格
剧目与剧情	本地资料或来源快照、幕次正文、图文向量	可追溯知识库与候选幕次
演员与角色	检测、对齐、向量匹配、显式身份注册表	稳定身份ID、当前剧目角色、演员专辑
场景复核	原图、候选、来源、修改/拒绝/确认	版本化决定、修订日志、最终标签
整理导出	连拍分组、选优、场景证据与命名规则	规范文件名、源图映射、复制/跳过报告
辅助视觉能力	RTDETR-X、YOLO分割/姿态、LAMA、图像检索	人像区域、景别、背景修复与相似图等既有接口

辅助视觉能力属于仓库已有功能，本报告的主实验集中于身份、幕次检索、视觉证据、任务可靠性与整理流程；未把所有辅助模型重新做精度横评。

浏览器检查覆盖1440、1024、768、540和390像素宽度，验证切图、草稿、刷新、导出、错误提示及任务状态。GPU操作在浏览器回归中部分使用替代响应；真实GPU流程另外报告，避免混淆验证层次。[S19]

模型能力与可靠性基础设施协同

系统采用Python服务端与轻量浏览器界面。FastAPI提供工作台与业务API；任务执行器承接长操作；共享特征服务减少重复编码；SQLite保存复核和任务状态。算法模块通过带版本的输入、输出和证据对象连接。

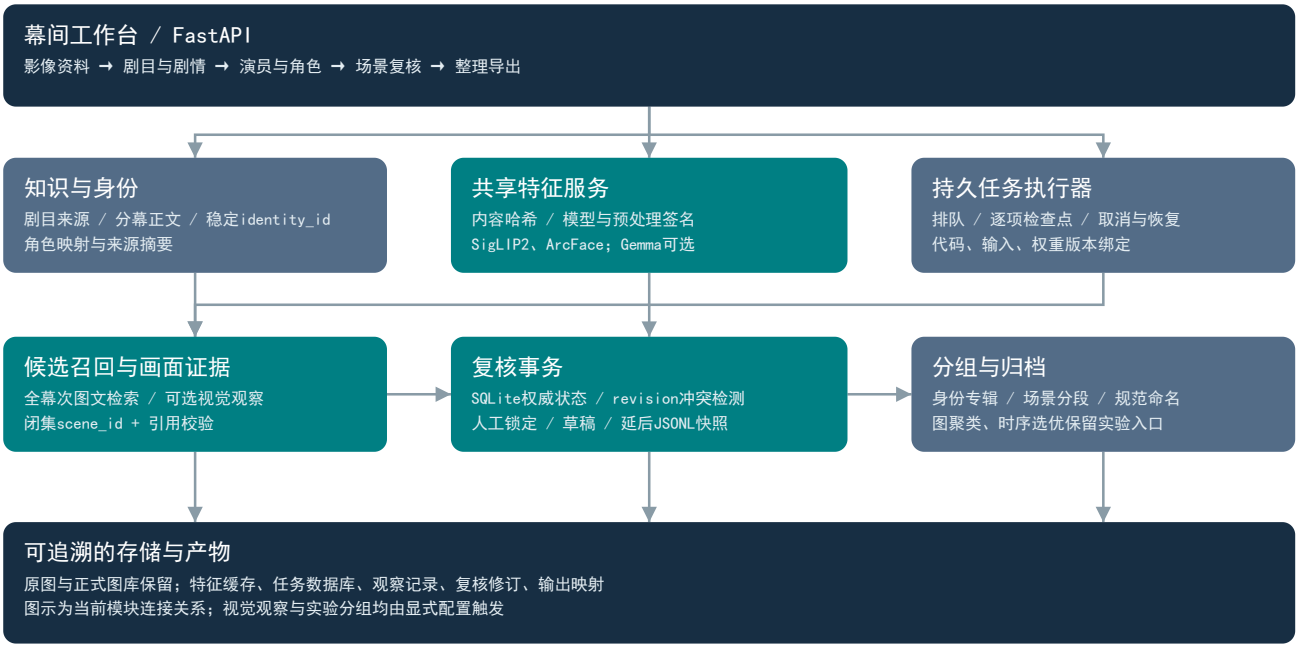


图2 当前模块架构。视觉模型与实验分组按配置触发，图中连线表达数据依赖，不表示每批任务都会运行全部模型。

三条相互约束的处理链

身份链：源图→检测框→五点对齐→人脸特征→身份级竞争→当前剧目角色。身份注册表解决“同一演员多个角色目录”和“同名不同演员”问题。

场景链：剧目来源→候选幕次→图文召回→可选画面/OCR证据→闭集判定→人工复核。机器判断保留候选与引用；人工决定锁定后，重分析不得覆盖。

执行链：输入清单→版本契约→逐项任务→检查点→原子发布。恢复前核对源码、输入、模型和配置；版本不一致时要求新建任务，防止将旧中间结果混入新流程。

> 工程边界：原图与正式图库作为受保护输入；实验使用隔离输出与图库副本。浏览器草稿是本地未提交编辑，SQLite中的已确认修订才是服务端决定。

明确“文件数”“图片数”和“标注数”

原始清单覆盖582份文件，包含原始照片、整理后副本及资料图。内容去重后有319张可解码图像，其中292张具有舞台照线索、27张具有资料图线索；类别线索仍有待人工复核，不能把文件副本当作独立样本。[S01]

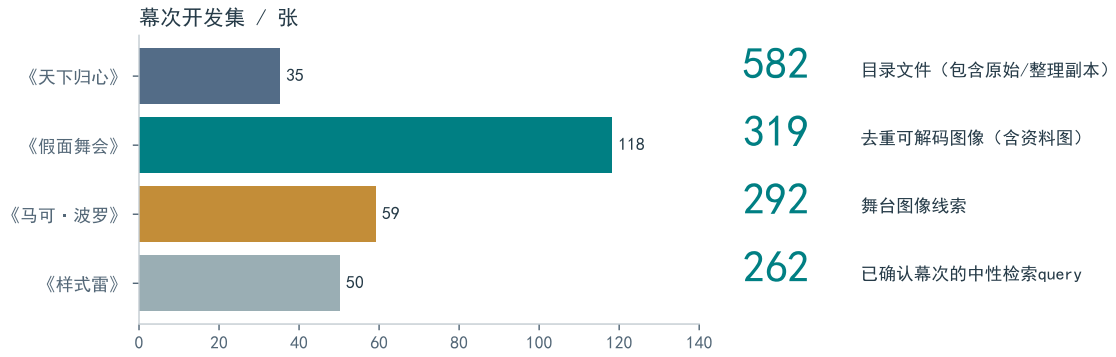


图3 本地数据范围与262张幕次开发集分布。四部剧目样本不均衡，假面舞会占118张。

数据对象	当前数量	可支持的结论
已确认整理文件名标签	263张	其中262张有幕次；人物列表不保证穷尽所有可见人脸
当前检索query	262张 / 4剧目	中性路径与图像输入下的开发集候选召回
剧目内身份	35个	注册表中的明确身份/角色关系，不等于35人已完成框级评测
正式图库裁剪	109份	来源待核验；108份裁剪的名称对应46张历史query
逐脸复核包	292图 / 1095脸	检测结果和原图框位置可追溯，人工身份标签仍为0
照片划分复核	375项 / 14相机流线索	场次、时钟、近重复、连拍、图库来源的待处理材料

数据隔离策略

检索使用中性PNG与不携带幕次、人物答案的路径；原标签仅用于评分。所有同源副本以内容摘要关联，图库与query需进一步隔离近重复及连拍。现有每剧目只有有限日期/场次线索，尚未形成可证明独立的final test。

262版本由旧260幕次版本补回两条已确认但被连字符解析漏读的标签，原260标签保留不变。历史报告的分母不被追溯改写，新协议分别报告历史260、新增2和全部262。[S02] [S03]

SCRFD检测、ArcFace表征与身份决策

SCRFD在多尺度特征上预测人脸置信度、边框和五个关键点，通过阈值过滤与非极大值抑制去除重复框。项目实测契约记录检测输入640×640、置信度阈值0.5、NMS阈值0.4。照片框位置需与缩放、解码方向一致，复核页面再投影回原图。[S12]

五点对齐与ArcFace：利用双眼、鼻尖、嘴角估计相似变换，将人脸映射至112×112标准输入；编码后得到归一化人脸向量，当前图聚类使用512维向量。对齐减少位姿差异，但侧脸、浓妆、遮挡与小脸仍会削弱身份信息。

$$L_{ArcFace} = -\log \{ e^{s\cdot\cos(\theta_y+m)} / [e^{s\cdot\cos(\theta_y+m)} + \Sigma_{j\neq y} e^{s\cdot\cos\theta_j}] \}$$

式中角度间隔m用于原模型训练，使同身份特征更紧凑、不同身份更分离；s为尺度。**本项目使用预训练模型推理，没有训练上述损失，也未重新估计m。** 推理阶段比较归一化向量的内积，即余弦相似度。

身份级聚合与拒识

先把属于同一`identity_id`的图库目录或锚定结果合并，再取该身份最大匹配分。这样多个角色目录不会互相成为“第二身份”，也不会把一张脸输出为多个演员。

$$S_k = \max_{a\in A(k)} \mathrm{sim}(f, a)；接受\ k^* \Leftrightarrow S_{k^*} \geq \tau\ 且\ S_{k^*} - S_{second} \geq \delta$$

τ为相似度阈值，δ为身份间分差；无第二候选时按实现仅检查阈值。分数、第二名、margin、锚定来源和拒绝原因一同保存。当前阈值与margin属于可配置工程参数，尚未由隔离的已知/unknown人脸集完成校准。

角色由当前剧目的已确认演员表关联。多角色冲突保留演员身份，不根据外观猜当前角色。文件名未列名不能用作unknown真值；unknown应表示不属于所选图库身份集合，而非“系统暂未识别”。[S17]

> 实测1095脸是检测结果集合，不覆盖漏检人脸，也不表示1095个真实人物。身份召回、未知误报率和框级聚类质量目前均未完成验收。

共享向量空间中的幕次检索

幕次候选检索把图像与场次文本编码到共同空间，图文向量分别L2归一化后计算点积。它度量语义相容性，不直接证明人物身份或精确幕次。

$$v = f_{image}(I) / \|f_{image}(I)\|_2;\ t = f_{text}(D) / \|f_{text}(D)\|_2;\ s(I,D) = v^T t$$

SigLIP2：双编码器与成对匹配

项目默认使用`siglip2-base-patch16-384`，图像输入384×384，输出768维特征。图像编码器利用视觉Transformer聚合patch信息，文本编码器提取文本语义。SigLIP系列的基础训练目标使用成对sigmoid匹配，而不是要求所有候选共享一个softmax归一化分母。

$$L_{pair} \propto \Sigma_{i,j} \log[1 + \exp(-y_{ij}(\alpha \cdot v_i^T t_j + \beta))]$$

y取正负配对标签，α、β为训练中的尺度与偏置。上式解释匹配目标；报告中的检索分数实际使用向量点积，未把训练logit当作校准概率。此本地配置的文本窗口为64 tokens，较长分幕正文会被截断，因此文本组织成为重要实验因素。[S03]

EmbeddingGemma 2：本地多模态嵌入接口

本地checkpoint的`model_type=embedding_gemma2`且含视觉配置。适配器使用SentenceTransformers，将多模态表示进行均值池化和归一化，输出768维向量。文档使用checkpoint定义的`Document`前缀（`title: none | text:`），图像使用空前缀；音频配置在本任务中关闭。

实现契约	SigLIP2 base	本地EmbeddingGemma 2
本任务输出	768维归一化向量	768维归一化向量
文本处理	tokenizer固定窗口、长文截断	checkpoint的Document提示与池化规则
模型入口	Hugging Face图文模型	SentenceTransformer多模态输入
数值与依赖	沿用冻结签名	支持时BF16，否则FP32；禁止FP16
默认状态	当前默认检索后端	显式可选实验后端

模型权重、预处理、文档前缀、软件包版本均进入签名；不同配置的向量不能直接混用。本文关于Gemma结构的描述以本地checkpoint与适配器为依据，未推断未核验的训练配方。

将文本覆盖与模型差异分开测量

原25候选中仅5个有分幕正文，其余20个主要是标签。来源增补后增加12个有出处的场次正文，另保留8项正文缺口；扩展28池追加《马可・波罗》的3个明确候选。来源正文与照片演出版是否完全等价仍需核验，尤其2014与2015巡演文本的调整不能静默合并。[S02] [S03]



图4 冻结向量与短文本块研究。25/28池从相同分数表取列，避免把重新编码漂移误当成候选竞争效应。

两种聚合、一个主方案

正文按可追溯原文跨度分成82个短块，每块不超过本地SigLIP2的64-token预算。历史研究保存102份去重文档向量；262协议复用它们，并补编码12份缺失基线标签文本。不是为每个变体重新编码全部图片。

$$s_{mean}(I,c) = |B(c)|^{-1} \Sigma_{b\in B(c)} v^{T}t_b;\ s_{max}(I,c) = \max_{b\in B(c)} v^{T}t_b$$

均值聚合是预先指定的主方案，各块等权；短尾块也会获得相同权重。最大值是次方案，可捕捉局部匹配，但块数较多的候选更容易取得偶然高分。即使最大值取得较好结果，也不能事后替换主方案并忽略偏差。

排序在**已知剧目内部**进行，25/28指跨4剧目的总候选数。各剧目的候选规模不同；《马可・波罗》原池仅3个候选，因此该剧原池R@3=100%具有结构性，不足以单独证明优秀检索能力。

先描述可见事实，再做闭集判断

视觉路径把图片本身传入模型，先收集服饰、道具、布景、动作、可见文字和不确定项，再结合剧情候选做闭集幕次选择。模型只能选择现有`scene_id`或`unknown`，引用必须指向已提供证据，数值字段和JSON结构也必须合法。

请求预算与失败行为

自动模式根据候选分差、证据不足等条件决定是否补充观察；图像额度、实际HTTP请求和最大输出tokens分别计数。预算以每次请求的上限预留，避免错误重试或隐式级联超支。无预算、观察失败或输出越界时保留降级原因并进入人工复核。

控制项	本次已验证行为
图像输入	EXIF方向处理、最长边限制；默认视觉预览最大边1280
观察结构	5类可见事实 + uncertain，字段校验后持久化
判定范围	候选幕次ID或unknown，禁止创造新幕次/伪造引用
自动预算实验	100图中15图观察，15次观察 + 15次闭集选择
按需材料收集	100图各1次观察，不进行新的闭集选择
重放	同进程缓存复用；两项实验的新增请求均为0

模型输出中的服装、动作与文字不能代替演员身份识别。独立双人复核按事实判断“支持/错误/不可评价”，并记录重复描述与遗漏；合法JSON比例与事实正确率是不同指标。[S05] [S06] [S18]

OCR提供补充文本，不生成身份真值

PaddleOCR以独立worker处理明确含字图片，返回文字行、位置和置信度等观察信息。实际5图实验检查了输入、模型摘要与缓存重建；目前无逐字人工参考，不能计算真实OCR准确率。复核界面只显示图片与空白转录框，不显示模型预测，以减少抄写预测造成的偏差。[S07]

> 远端服务别名为Qwen3.6-27B，配置声明为Qwen3.8-27B。元数据接口没有提供可核验的权重摘要；本报告称其为“现有视觉服务”，不据名称推断实际参数规模、版本或模型架构。[S20]

从局部相似度到受约束的候选分组

人脸图聚类：互近邻、不能合并约束与漂移控制

对归一化ArcFace向量执行FAISS精确内积近邻搜索。两个点互为k近邻且相似度达标时生成边，再按边分数顺序合并簇。合并需同时通过簇大小、cannot-link、质心相似度和所有成员对新质心的最低相似度检查，避免“相似链”逐步跨越身份。

参数	当前实验默认	作用
k近邻数	16	控制候选边数量
边相似度	≥0.60	排除弱局部连接
质心/成员相似度	≥0.65	限制合并后的身份漂移
簇大小上限	512	限制单次成员检查开销
同图不同检测框	假定cannot-link	镜像、合成、重复检测需人工例外

复杂度边界：实现避免构造Python层N×N矩阵，边存储约O(Nk)；但`IndexFlatIP`仍是精确搜索，计算复杂度约O(N²d)，不能据此声称整体线性扩展。[S08] [S09]

窗口变化点：相邻视觉分布的差异

利用归一化特征的前缀和计算边界左右窗口向量和，取余弦距离作为变化分数；按峰值贪心选点，同时约束最短段长。当前默认窗口4图、最短段4图、阈值0.12，长时间间隔参数300秒。

$$g(t) = 1 - \cos\left(\Sigma_{i=t-w \ldots t-1} v_i, \Sigma_{i=t \ldots t+w-1} v_i \right)$$

评分阶段约O(Nd)，但有序峰值插入在最坏情况下仍可能O(N²)。视觉变化是边界候选；灯光变化、机位切换、彩排回演不自动等于剧情换幕。

连拍研究：可信时序与同配额选优

只合并同一可信相机流中的邻近图片：相邻间隔≤2秒、整组跨度≤8秒、首尾视觉相似度≥0.97，最多24张；已确认幕次冲突禁止合并。时间不可信时保守输出单图组。后续选择按相同保留配额比较质量与多样性；现有262图仅1个两图组，不满足选优评测条件。[S10]

让长流程能够安全恢复

每个长任务保存输入清单、模型与源码契约、逐项状态及阶段检查点。人脸任务将检测、对齐裁剪和预览分别持久化；恢复时复用已完成文件，避免重跑检测或裁剪。复制前后验证源文件摘要，输出采用临时文件与原子替换。[S12]

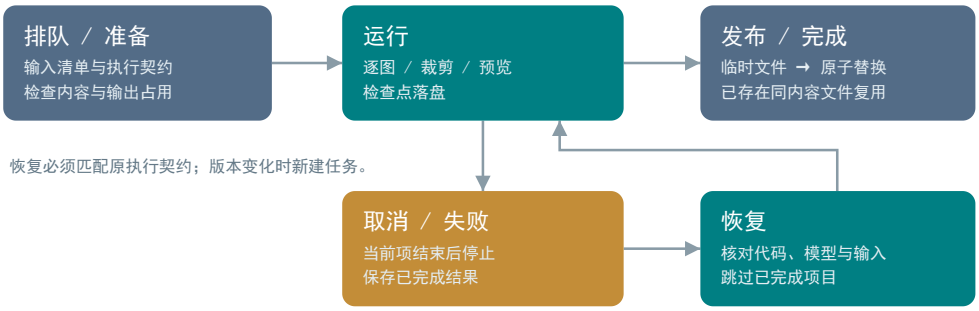


图5 简化任务状态与恢复路径。取消确认表示已接受停止请求，实际停止仍需等待当前项结束。

内容缓存的有效性条件

图像缓存键以内容摘要关联，叠加模型权重和预处理签名、维度与数据类型。文件大小和修改时间可加速检测，但不能代替最终内容证明。模型权重或代码变化时检查点失效，不能通过修改任务状态强行续跑。

远端权重未核验时保留进程私有身份，阻止把“服务名称相同”误当成跨进程模型完全相同。视觉请求的同进程重放成功因此只证明本进程缓存复用。

SQLite作为复核权威状态

服务端以事务保存决定和不可变修订历史，客户端携带`expected_revision`；同条记录被其他客户端修改时返回冲突，刷新最新记录并保留本地草稿。机器重分析只更新pending候选，保留人工确认或拒绝。

工作台的单条保存显式启用`defer_snapshot`，先提交SQLite，再在导出时生成兼容JSONL。旧调用默认即时快照；元数据与当前页详情从数据库读取。快照缺失或旧文件未更新时，场景证据也读取权威数据库，避免“保存成功、整理却读旧标签”。[S13]

恢复可靠性与吞吐改善分别衡量。事务、检查点和内容校验会带来开销，但它们防止半写文件、重复发布、人工决定丢失及版本混用。

采用冻结协议，保留各实验的测量范围

本文汇编的是2026-10-21—24期间的多组实验，不是一次统一、独占硬件的最终benchmark。每组报告保留自己的源码摘要、输入、模型身份和运行日志；下列环境来自对应原始记录。[S04] [S08] [S12] [S21]

项目	报告记录的设置
主要GPU	NVIDIA GeForce RTX 3090，24 GiB；U4/U3等使用物理GPU1；共享占用
CPU规模实验	Montage Jintide C4215R，32逻辑CPU；独立worker，每方法4线程
视觉运行环境	Python 3.10环境；PyTorch 2.9.0+cu130；部分报告Transformers 5.15.0
ONNX人脸推理	ONNX Runtime GPU 1.23.2；真实292图契约为CUDA + CPU provider
Gemma隔离依赖	requirements中固定Transformers 5.20.1、SentenceTransformers 6.1.0等；具体运行签名另存
批量/解码	历史U2 batch=8、decode workers=2；torch CPU线程16
CPU合成特征	seed=20261023；噪声σ=0.006；窗口768维、脸聚类512维

实验矩阵

研究	样本与重复	对照及保持项
幕次检索U4	262图，2后端×7变体	固定query/GT；25/28池，长文/短块均值/最大值
视觉证据U5	自动100图；按需另100图	实际请求计数、结构校验、重放缓存
分组规模U6/U7	10000预计算特征，每方法1次	图与层次聚类共享同一512维输入；特征生成不计时
HTTP可靠性U3	292真实图、5客户端、60秒、总5请求/秒	一万条复核元数据负载；查询与任务创建分别统计
U2性能	200唯一图/4剧目/8目录，各5次	corrected baseline对批量/缓存，分阶段计时
整理工作流U8	200图/4项目，两种输入形式各1轮	原始文件与已整理命名分别验收，均使用隔离图库

262检索协议每后端只新增编码2张图和12份文本，历史260图与102文档向量直接复用。增量编码时长不能拿来比较两模型完整吞吐。各性能实验共享资源、计时边界与重复次数不同，不将它们拼成一条总加速曲线。

使每个百分比都能追溯到分母

幕次召回与分类

$$\text{Recall@K} = (1/N)\ \Sigma_{i=1\ldots N}\ \mathbb{1}[y_i \in \text{TopK}(i)]$$

当前各图使用一个已确认幕次标签，N=262；Top-1命中率可视为当前闭集标签下的准确率。R@3用于衡量候选列表是否覆盖正确场次，不能代替自动选中第一名的质量。候选按剧目内排序，小候选池会天然抬高R@K。

$$F1_c = 2TP_c / (2TP_c+FP_c+FN_c);\ \text{Macro-F1} = (1/|C|)\ \Sigma_{c\in C}\ F1_c$$

262研究的Macro-F1按协议预声明的25个已确认GT幕次类计算；扩展的3个无正例候选不新增为GT平均类别，但预测落入它们会令真实类别产生漏报。`scene_macro_recall_at_1`不是Macro-F1，本文不将二者混用。[S02]

人脸、事实、文字与性能

指标	正确解释与当前限制
B-cubed P/R/F1	每个已标注人脸在预测簇与真实身份簇中的交集比例；当前仅对明确known、可评价、非例外子集定义
unknown FPIR	未知query被错误接受为图库身份的比例；需隔离gallery/query及足量未知真值，当前为空
事实错误率	双人已完成且一致的error / (supported + error)；pending、分歧和不可评价单列
OCR CER	编辑距离总和 / 参考字符总数；只使用双人转录一致项，空分母保持null，插入可令CER>1
HTTP P95	对原始请求延迟样本取95百分位；取消只有1次，应读作单次确认耗时
峰值RSS	对应worker进程的常驻内存峰值；不等同GPU显存，也不是算法数组净内存
speedup	相同测量边界内T基线/T候选；不跨不同输入范围和计时协议比较

检索配对分析保留“新增命中/失去命中”，同时按4剧目重采样生成探索性区间。仅4个剧目且未按独立演出、近重复组完成分层，区间不能视为对新演出的最终泛化保证。[S02]

14种变体在同一262图开发集上的结果

表中所有百分比由保存的整数命中数与原始指标生成。25/28是跨剧目候选总量；“原文基线”使用冻结向量重建，不是重放所有历史独立运行。主方案为短块均值，最大值为次方案。[S02]

后端	文本/候选池	Top-1	R@1	Top-3	R@3	Macro-F1
SigLIP2	原文基线 · 25	49	18.70%	143	54.58%	12.10%
SigLIP2	增补长文 · 25	38	14.50%	160	61.07%	10.53%
SigLIP2	短块均值 · 25	61	23.28%	183	69.85%	13.43%
SigLIP2	短块最大值 · 25	61	23.28%	180	68.70%	14.24%
SigLIP2	增补长文 · 28	37	14.12%	129	49.24%	10.19%
SigLIP2	短块均值 · 28	60	22.90%	140	53.44%	13.42%
SigLIP2	短块最大值 · 28	57	21.76%	153	58.40%	13.74%
Gemma 2	原文基线 · 25	43	16.41%	148	56.49%	12.67%
Gemma 2	增补长文 · 25	80	30.53%	190	72.52%	20.61%
Gemma 2	短块均值 · 25	72	27.48%	200	76.34%	15.69%
Gemma 2	短块最大值 · 25	101	38.55%	202	77.10%	25.31%
Gemma 2	增补长文 · 28	61	23.28%	176	67.18%	17.55%
Gemma 2	短块均值 · 28	56	21.37%	188	71.76%	14.72%
Gemma 2	短块最大值 · 28	83	31.68%	184	70.23%	23.92%

如何解读这张表

主方案的Top-3改善强于Top-1。 25池Gemma短块均值为72/262 Top-1、200/262 Top-3；SigLIP2为61/262、183/262。候选覆盖较好不意味着第一名已足够可靠。

最大值结果需要保留选择偏差说明。 Gemma最大值25池R@1=38.55%、R@3=77.10%、Macro-F1=25.31%，是本表较高结果，但它是次方案，存在块数偏置，没有独立final test支持默认替换。

新协议和历史数值不可混写。 旧260独立Gemma原文基线为45/151命中；当前冻结向量重建的历史子集为42/147，全262为43/148。六种长文/分块历史结果与向量则按协议精确保留；基线差别被明确记入报告。[S02]

更完整的短文本覆盖改善候选召回

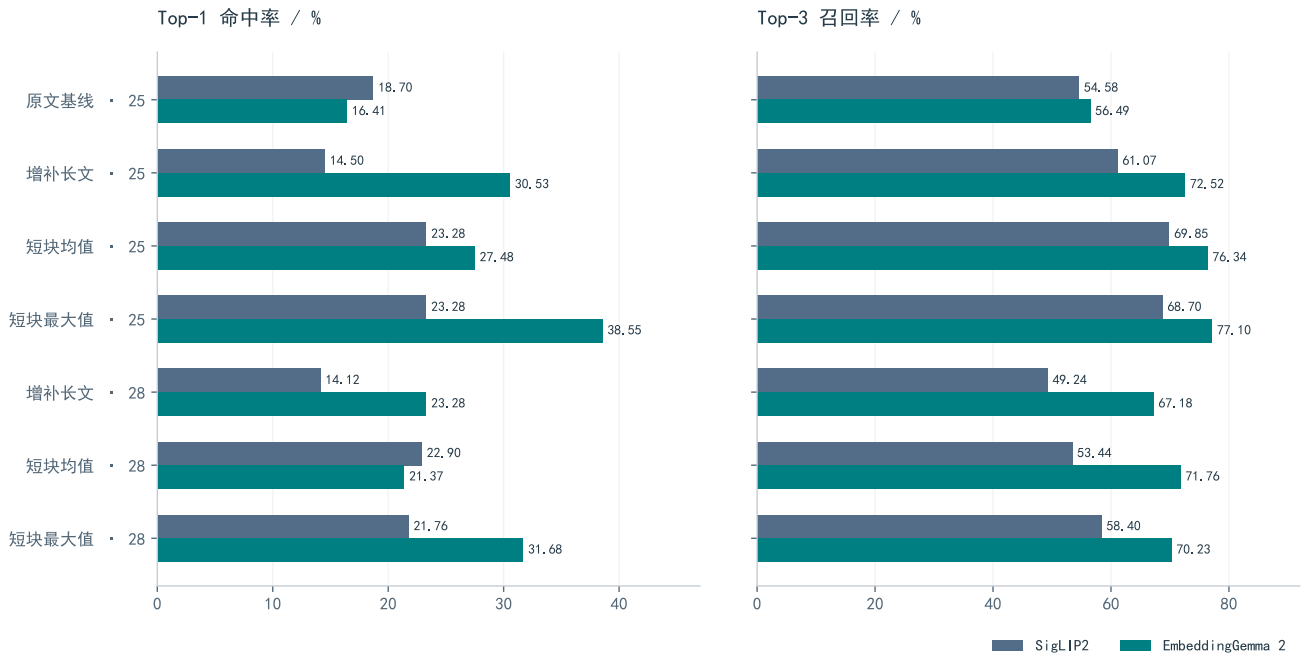


图6 两模型七种文本/候选配置的R@1与R@3。颜色区分模型，不同池和聚合方法分别展示，未将次方案作为主方案。

25池内，SigLIP2从增补长文的61.07% R@3提升到短块均值的69.85%，增加23张命中；Gemma从72.52%提升到76.34%，增加10张。分块缓解短窗口截断，并使不同内容段分别进入候选评分，但收益随剧目和聚合方式变化。

同方案模型配对比较

对比：Gemma − SigLIP2	R@1差值	R@3差值	R@3新增/失去命中
短块均值25池	+4.20 pp	+6.49 pp	+52 / −35，净+17
短块均值28池	−1.53 pp	+18.32 pp	+86 / −38，净+48

均值25池R@3差值的四剧目探索性重采样95%区间为[+0.92, +10.46] pp；28池为[+4.71, +41.41] pp。28池更大的差值主要受马可新增候选竞争影响，不能直接解释为所有类型剧照都得到同等收益。

> pp表示百分点。以上是开发集上的配对观察，数据独立性与演出版等价性尚不足，当前默认继续保留SigLIP2。

总体提升掩盖了明显的剧目差异

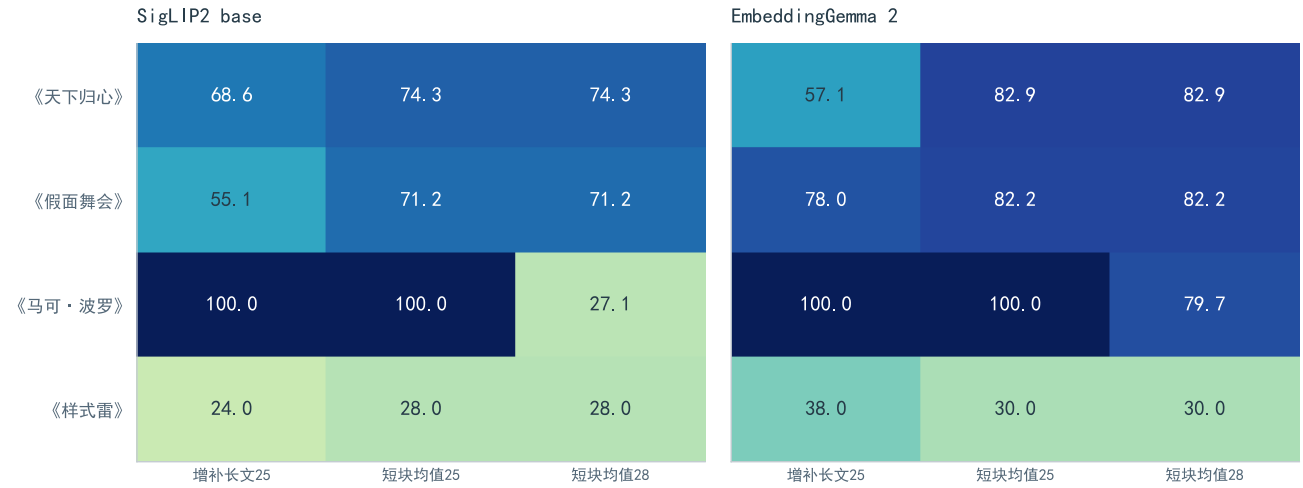


图7 各剧目R@3热图（%）。马可在25池仅3候选，Top-3必然覆盖整个池；扩池后的下降揭示竞争敏感性。

《样式雷》是当前明显短板：Gemma增补长文25池R@3=38.0%，短块均值降至30.0%；SigLIP2相应为24.0%与28.0%。平均收益不能替代对困难剧目、缺失正文和特定场次的诊断。[S02]

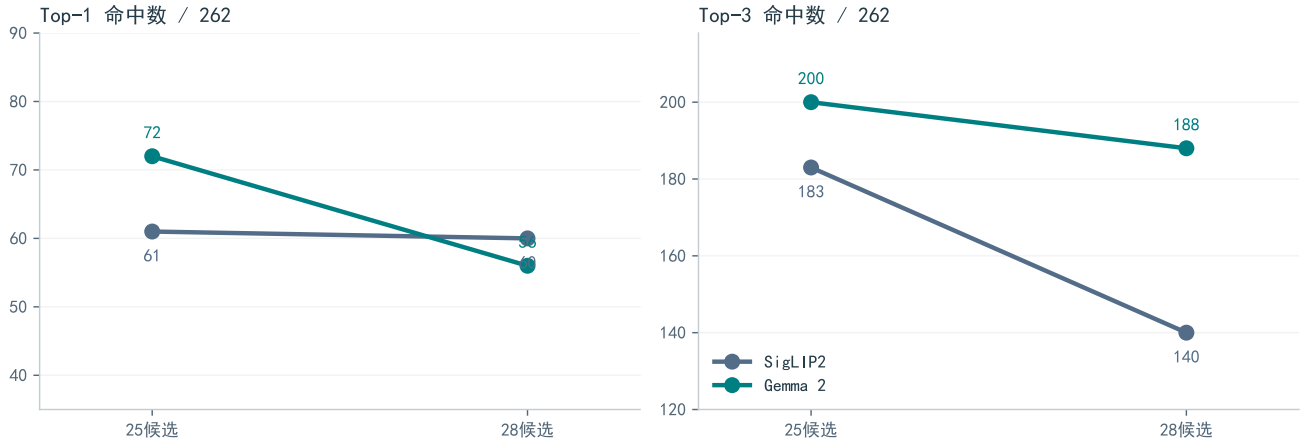


图8 短块均值从25扩展到28候选后的命中数变化。相同图文分数，仅增加候选列。

扩池时，SigLIP2 Top-3从183降至140（−43张），Gemma从200降至188（−12张）；新增竞争全部作用于马可。该剧59图的均值R@3从两模型均为100%降为27.12%与79.66%。新增第三/第四幕及尾声候选缺少对应正例query，因此当前测试不能证明完整候选池上的分类能力。

真实请求已经验证，事实质量仍待人工

实验	输入图数	实际观察图	观察请求	闭集请求	HTTP总请求	重放新增
自动预算	100	15	15	15	30	0
按需复核材料收集	100	100	100	0	100	0

自动实验有效schema比例为100%，15次闭集选择通过约束校验，越界选择为0；14项完整性检查通过。按需实验生成100份有效观察，10项检查通过，耗时429.52秒；该耗时包含远端服务等待，不是同模型受控吞吐测量。[S05] [S06]

为什么schema通过不能写成“事实准确率100%”

schema只验证字段类型、枚举、候选ID与引用是否合法；一个格式正确的描述仍可能认错道具、动作或文字。现有100图共1352条可复核事实，A/B两位实际复核人数为0，因此事实错误率必须为`null`，而不是0%。[S18]



图9 实际双人事实复核页面（局部）。测试中的临时姓名和决定仅为脚本交互，不产生人工事实标注。

5图PaddleOCR实验完成真实处理与缓存重建检查，但尚无一致参考转录，CER同样为空。复核工具把不确定、不可评价、分歧、重复描述及遗漏分别记录；不以丢弃困难项的方式提高结果。

远端缓存证明局限于当前进程，实际权重摘要仍缺失。更完整的质量报告需要两位独立复核人、足够图像覆盖、明确分母，以及与幕次判定效果的联合评测。

规模检查通过，身份与边界质量未定

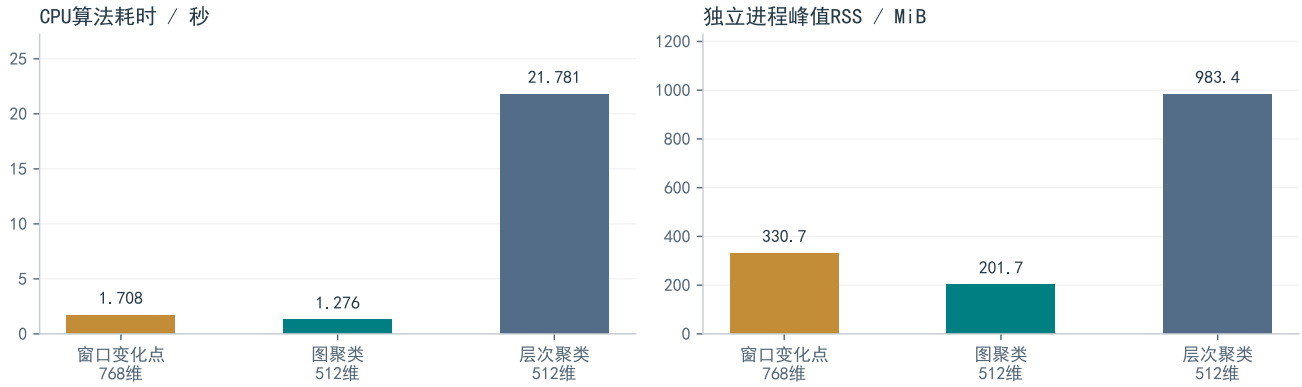


图10 10000条固定合成特征的CPU规模观察。特征生成在计时前完成，每方法独立进程仅运行一次，不能当作端到端模型加速。

方法	输入维度	耗时	进程峰值RSS	数据与结论范围
窗口变化点	768	1.708 s	330.7 MiB	预计算序列，算法规模检查
图聚类	512	1.276 s	201.7 MiB	与层次聚类相同合成人脸向量
层次聚类	512	21.781 s	983.4 MiB	对照实现，合并策略与图方法不同

图聚类/层次聚类的本次算法耗时比为17.066倍，RSS约为后者20.5%；共享CPU、单次运行和不同合并策略限制了结论。真实身份质量可能随着更保守的合并策略而出现过分裂，不能以速度证明聚类更好。[S08]

真实1095脸与262图探索

同一组1095脸向量上，legacy生成453簇，graph生成616簇；4200对假定同图cannot-link约束的违反数由29降为0。这只验证算法遵守提供的约束，镜像与重复检测例外尚未核对；框级身份标注为0，B-cubed F1不能计算。[S09] [S17]

262图的14条相机流线索缺少可信时钟/连续性核验。保守策略输出262个单图组；仅探索性放宽时序假设后得到260个单图组及1个两图组，三张以上连拍组为0。无法开展60个三图以上连拍组的正式选优评测，也不能计算真实边界F1。[S10]

> DINOv3、AdaFace、TOPIQ与MUSIQ在本轮没有运行对照，属于待验证研究选项。默认分段与人脸聚类均保持legacy。

长任务期间保持可查询、可取消、可复核

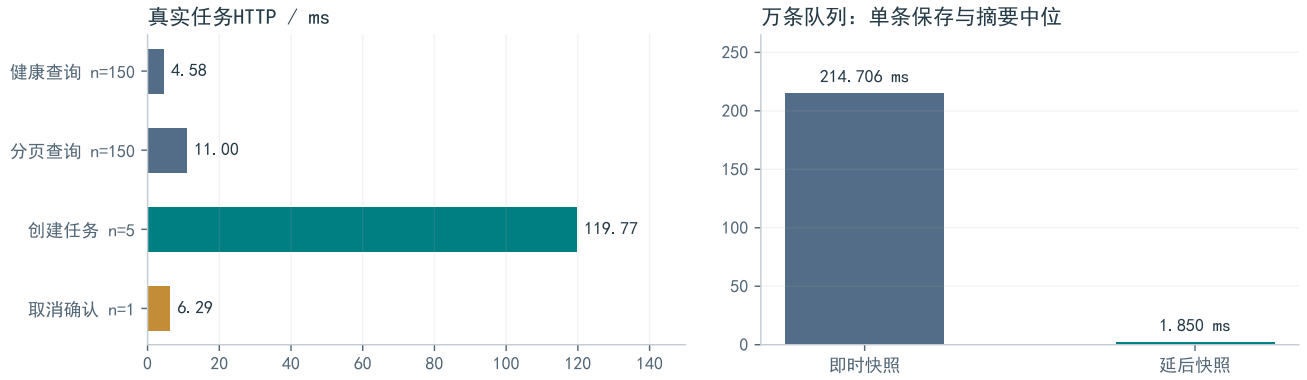


图11 左：真实292图任务运行时的HTTP延迟；查询/创建显示P95，取消显示单次确认耗时。右：万条合成复核队列的本地保存及摘要中位耗时。两图属于不同实验。

真实HTTP任务响应

5客户端、60秒、总5请求/秒、10000复核记录负载下：健康查询150次P95=4.577 ms，分页查询150次P95=10.998 ms，5次不同任务创建P95=119.771 ms；单次取消确认6.288 ms，最终停止等待约10.504 ms。10项检查通过，HTTP错误0。[S11]

复核快照：减少每次决定的全量文件工作

保存模式	5次中位：保存+摘要	保存期间JSONL替换次数	重启读取	导出一致性
旧即时模式	214.706 ms	10	读取最新决定	通过
工作台延后模式	1.850 ms	0	SQLite读取最新决定	通过

本实验用10000条合成记录，同一机器顺序执行，计时包含单条决定和摘要查询。差异主要反映避免每次重写完整兼容快照；这不是HTTP并发测试，也不是图片整理端到端加速。报告绑定版本早于后续“无快照场景证据读取”修复，应保留其原版本范围。[S13]

工作台另验证了一次元数据加载、详情批次36/36/1、全队列详情请求0。单条决定后更新对应记录与统计；冲突时刷新该条并保留草稿。存储13项、工作台API 27项和五屏宽浏览器已有通过记录，具体测试版本保留在完成核查目录。[S19]

分阶段结果不能替代完整验收

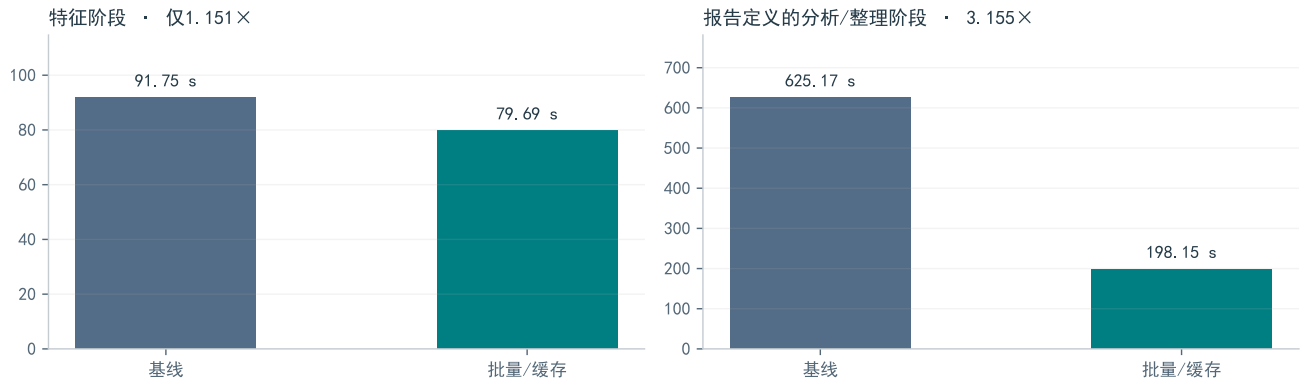


图12 历史200图×5次实验的阶段耗时中位数。两个面板采用各自纵轴，分别解释特征阶段与报告定义的分析/整理阶段。

指标	corrected baseline	批量/缓存方案	比较
特征阶段中位耗时	91.750 s	79.689 s	1.151×，下降13.15%
特征阶段吞吐	2.180 图/s	2.510 图/s	未达既定提升门槛
分析/整理阶段中位耗时	625.165 s	198.152 s	3.155×，下降68.30%
特征进程峰值RSS	2253.0 MiB	2490.6 MiB	增长10.55%
分析/整理进程峰值RSS	3133.7 MiB	3309.7 MiB	增长5.62%

原报告检查了图文向量一致性、缓存命中零前向、分析到整理缓存复用、决定与质量分一致性及资源约束。11个检查项中，`feature_speedup`未通过，因此正式性能状态保持`not_passed`。[S14]

测量边界与解释

分析/整理阶段的较大收益与避免重复编码、跨步骤复用有关；它不表示每个模型前向都提速3.155倍，也不能替代独立final test上的完整业务成本。实验使用共享RTX 3090，冷/热缓存、模型加载和其他进程负载影响必须依照原日志解释。

R@K、身份GT、偏好GT等正式质量数据仍不足，因此“输出决定一致”只是相对corrected baseline的行为一致，不是准确率证明。人脸TensorRT在仓库中有可选支持，但本次292图任务契约记录的是CUDAExecutionProvider；本报告没有把其耗时称为TensorRT性能。[S12]

> U2提速、解码优化与DALI按用户指示暂停。本报告只整理已有实验，没有恢复该工作，也没有以其他局部速度结果更改U2未通过的结论。

从候选到导出，再到规范命名

真实流程以4个项目共200张图，执行分析→脚本复核/冲突→导出→重分析保护→整理。每项目16项检查，加6项跨项目检查，共70项；使用实际本地模型、隔离图库，`use_llm=false`。脚本复核用于验证行为，不新增人工标注。[S15] [S16]

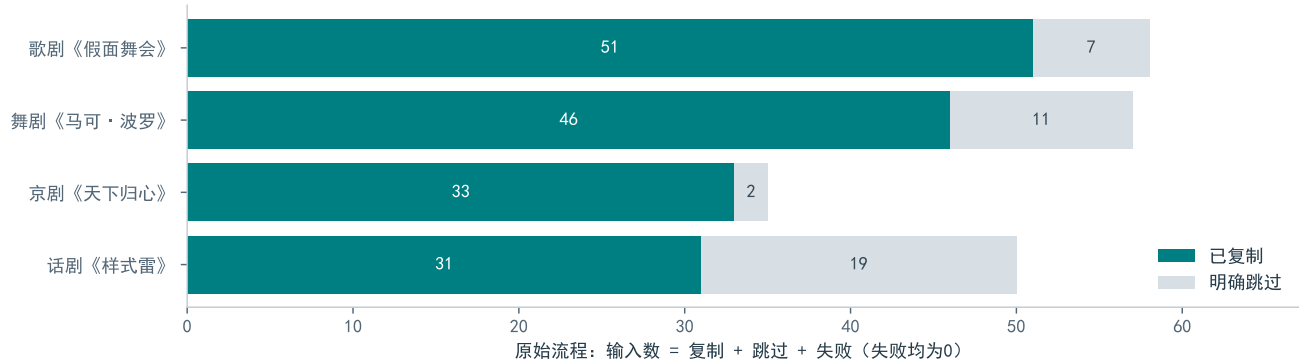


图13 原始200图流程的复制与明确跳过数，所有项目失败数均为0。跳过来源于该配置的分组/选优策略，不能自动解释为人工认可的淘汰。

输入范围	输入	复制	明确跳过	失败	检查
原始摄影文件名	200	161	39	0	70通过
已整理文件名再次处理	200	200	0	0	70通过

两种结果不是同一质量配额的算法横评。已整理序号需保持独立分组依据；不能因为普通目录中的名称相似，就把本已整理的不同序号重新误并为连拍。解析器修复同时保留日期、剧场和事项，当前项目未批准的旧幕次使用占位，不混入事项文本。

早期200图实验误用整理副本且命名范围不合格，原失败审计保留；后续分原始输入和已整理命名各自验证。该更正体现了“流程可跑通”和“输入范围符合规范”的区别。

四次服务恢复

292图人脸任务经历计划取消、首裁剪取消、首发布失败和重启完成，最终1095脸、453簇、0失败。17项检查验证不重复检测/裁剪/预览、每份文件只新建一次，并复用1份部分发布文件。源图、图库副本和受测源码摘要均按报告核查。[S12]

U8功能闭环已经有实测支持；正式U8仍缺U0—U3完整门槛、独立质量数据和受控端到端成本，状态保持`not_passed`。

把“缺少真值”转化为可执行的数据任务

目前已经准备好两条人工复核路径：逐脸身份复核和双人事实/OCR复核。它们保留原图位置、固定观察内容和协议摘要，导出后由评测工具校验；不会自动应用到正式图库，也不自动锁定final test。

材料	规模	当前人工完成	指标状态
照片/来源划分复核	375项	未完成正式核验	场次/连拍/图库隔离待定
逐脸身份	1095脸，35身份可选	0	B-cubed、已知召回、unknown FPIR为空
双人画面事实	100图，1352条	0	一致事实错误率为空
双人OCR转录	5图	0	CER为空

逐脸决定约束

已知身份必须指向注册表中的ID；unknown与不可评价分开。镜像和重复检测例外单列。984张对齐裁剪直接复用既有PNG，111张使用历史检测框上下文裁剪，记录为未对齐；无新增检测。只有明确known、可评价且非例外的人脸进入当前B-cubed子集。[S17]

双人评测边界修复

工具要求A/B两份不同复核人草稿、相同协议和完整来源绑定，禁止修改图像摘要、事实陈述或OCR预测。每种任务内，相同原图字节不能通过不同条目ID重复计数；一张图片同时用于画面与OCR任务则允许。

新增测试先复现7个校验遗漏：协议、源图、事实、预测、槽位混用，以及视觉/OCR重复图内容。修复后15项测试通过；既有v2包由修正后的评测工具重新校验，页面与模型结果不重建。人工标签仍为0。[S18] [S19]

质量材料与浏览器脚本的边界

17项事实浏览器检查证明分页、独立草稿、刷新、导出/恢复、OCR不预填及存储失败提示可用。脚本填入的临时决定不计作人工复核；姓名字段不同也不能单独证明两人独立审阅。真实质量工作还需要合格复核流程与分歧处理。

下一阶段的重点是可信质量证据

阶段	已获得证据	尚缺关键条件	当前采用
U0 数据/基准	去重清单、263/262标签、375复核材料	独立场次、近重复/图库隔离、final test	保留开发集定位
U1 身份	身份ID/角色契约、逐脸决策、1095脸复核包	≥200已知、≥300未知、≥10演员的隔离query与校准	正确性修复启用
U2 性能	200图×5阶段比较、一致性检查	特征吞吐门槛与正式质量成本	未通过；暂停
U3 可靠性	事务、任务恢复、HTTP和快照检查	受控整链路成本、远端权重证明	工程改动启用
U4 幕次	262图、14变体、276项结果审计	8正文、新候选正例、演出版与独立测试	SigLIP2默认
U5 画面事实	实际图片请求、预算、OCR和复核工具	双人事实/参考转录、判定Macro-F1增益	按预算辅助
U6/U7 分组	真实向量探索、万条规模检查	真实边界、身份例外、连拍偏好及新模型对照	legacy默认
U8 整链路	原始/已整理200图各70功能检查	必选阶段质量与性能门槛	正式未通过

建议的研发顺序

首先补数据与复核。 优先核对图库来源、已知/unknown人脸与相机时序；准备独立演出或剧目留出集。现有标签可支持迭代，但不能通过改文件名将已用开发图片变成final test。

其次修复文本覆盖并做预声明比较。 补足缺失场次正文和马可新增候选正例，核验演出版；冻结主指标、候选池和聚合方案，再评估模型替换。对样式雷等困难子集单列收益与退化。

最后统一质量与成本决策。 在用户恢复U2后，独立控制硬件负载、缓存、加载边界和重复次数；同时报告准确率、资源峰值、失败/降级与端到端时间，避免只选择好看的阶段指标。

已达到的工程收益应保留；Gemma、图聚类、窗口分段与连拍模型继续作为显式实验选项。当前证据不足以支持全自动演员/幕次标注或默认算法全面替换。

从图表回到冻结输入和原始报告

本报告的表格和统计图由`build_figures.py`直接读取原始JSON生成，完整数值另存`data/retrieval_metrics.csv`；`data/evidence_index.json`记录来源路径与SHA256。HTML内嵌所有图像，可离线阅读；PDF使用同一正文和样式排版。

只读复现入口

以下命令在仓库根目录执行，只验证已保存结果；需本地原始依赖文件齐全。它们不会重新调用模型，也不会覆写历史研究协议。

```
python outputs/reports/technical_report_20261024/build_figures.py
python outputs/reports/technical_report_20261024/build_report.py

# 使用项目Python环境执行已有数组审计
python outputs/acceptance/core_upgrade/\
u4_retrieval_study_262_gpu_retry_20261022/\
analyze_saved_results.py --verify-existing
```

前两条重建当前报告图表与HTML；PDF生成及分页检查使用报告目录中的渲染脚本。科学图表保留SVG和PNG两种版本，可独立用于后续汇报。正文可在`report_source.md`编辑；`technical_report.md`是展开数据表后的阅读版本。

关键实现位置

模块	代码位置（相对仓库根）
人脸检测/对齐/表征	`core_modules/face_recognition/`
图文特征与Gemma适配	`core_modules/image_search.py`、`organize/embedding_gemma.py`
身份与角色	`core_modules/organize/identity_registry.py`
观察、预算、闭集判定	`visual_evidence.py`、`scene_reasoner.py`、`llm_client.py`
图与时序算法	`face_graph_cluster.py`、`scene_change_points.py`、`temporal_burst.py`
复核与恢复	`review_store.py`、`review_queue.py`、`task_queue.py` 及各任务实现
评测	`tools/evaluate_face_identity_review.py`、`prepare_visual_fact_review.py`

上表中未写前缀的算法文件均位于`core_modules/organize/`。本报告不将本地模型声明当成远端权重证明，也不引入尚未运行模型的公开benchmark数字。模型原理参考：ArcFace（CVPR 2019）；SigLIP/SigLIP2官方论文与big_vision实现；SCRFD/InsightFace官方实现；FAISS官方文档；Gemma本地模型卡、配置与SentenceTransformers接口；PaddleOCR官方实现。

实验来源与核验说明

下表是全文 [Sxx] 的来源。路径均相对 outputs/acceptance/core_upgrade/；完整SHA256见随附JSON索引。大型向量、原始图片和任务数据库保留在本地实验目录，报告本身不包含所有原始数据。

编号	证据内容	报告文件
S01	照片清单与复核范围	u0_partition_review_20261022/artifacts/summary.json
S02	262图检索比较与配对分析	u4_retrieval_study_262_gpu_retry_20261022/summary.json
S03	冻结262图研究协议	u4_retrieval_study_262_20261022/prepared/protocol.json
S04	短块实验硬件预检	u4_text_blocks_20261022/preflight.json
S05	自动视觉预算100图	u5_visual_budget_host_20261023/summary.json
S06	按需视觉观察100图	u5_fact_observations_host_20261024/summary.json
S07	真实OCR五图	u5_ocr_verified_20261023/summary.json
S08	CPU万条特征规模检查	u6_u7_cpu_scale_20261023/summary.json
S09	1095脸真实图聚类	u7_graph_real_1095_20261023/summary.json
S10	262图时序/连拍探索	u6_u7_temporal_real_20261023/summary.json
S11	292图真实任务HTTP响应	u3_cluster_http_292_20261023/summary.json
S12	292图四次服务恢复	u3_cluster_recovery_292_20261023/summary.json
S13	复核快照一万条记录	u3_review_snapshot_scale_20261023/summary.json
S14	U2两百图五次基准	u2_publication_200x5_20261021/summary.json
S15	原始200图全流程	u8_raw_workflow_200_20261023/summary.json
S16	已整理200图重处理	u8_organized_reprocessing_200_host_20261023/summary.json
S17	1095脸待定评测	u1_face_quality_pending_20261024/summary.json
S18	双人事实待定评测	completion_audit_20261024/pending_fact_review.json
S19	最终文件与验证核查	completion_audit_20261024/summary.json
S20	远端模型元数据	remote_model_metadata_host_20261023/summary.json
S21	U2实际执行环境	u2_publication_200x5_20261021/batch.json

最终接续核查记录5647项检查、3365份唯一文件摘要匹配（包含582源文件和109图库文件），汇总6组107项既有通过测试，其中本轮新事实测试15项，其余沿用对应版本日志。检查数量不可当作独立质量样本量。[S19]

报告版本：2026-10-24 · 技术评审与研发版 · 代码 ad68c89。图中舞台照片来自现有本地样本，仅为功能与场景说明，未按模型成功率挑选。浏览器图像来自既有验收过程；脚本草稿不计人工标注。正文、可视化和排版均在本地生成，撰写过程模型推理请求为0。

方法文献与本地实现依据

以下资料用于解释算法思想和接口；其中公开模型或论文的性能不被转引为本项目结果。实际参数以本地配置与各实验签名为准，尤其远端视觉服务无法由名称验证其权重。

参考	方法或实现依据	与本系统的关系
R01	Deng et al. *ArcFace: Additive Angular Margin Loss for Deep Face Recognition*. CVPR 2019. 论文	角度间隔训练目标；系统使用预训练向量推理
R02	*Sample and Computation Redistribution for Efficient Face Detection*. 论文；InsightFace SCRFD	多尺度人脸框与关键点检测
R03	Zhai et al. *Sigmoid Loss for Language Image Pre-Training*. ICCV 2023. 论文	成对sigmoid图文匹配目标的基础
R04	Google big_vision · SigLIP2	SigLIP2编码器、模型配置与实现依据
R05	FAISS	归一化人脸向量的精确内积近邻搜索
R06	SentenceTransformers与本地EmbeddingGemma 2配置	Document前缀、多模态输入、均值池化与归一化
R07	PaddleOCR	图片文字检测与识别工具链

本地参数与协议的证据层次

1. **方法思想**：原模型论文与官方实现描述训练目标和结构，不代表本项目重新训练。
2. **本地适配**：SigLIP2配置、Gemma的`modules.json`、`1_Pooling/config.json`与提示配置决定实际编码方式。
3. **实验执行**：冻结源码、模型/预处理摘要、请求记录与向量数组决定某个结果的可复现范围。
4. **质量结论**：独立数据划分、可靠人工真值、预声明指标与受控实验决定能否采用新方案。

四层证据不可互相替代。例如CPU规模实验验证计算与内存范围，不能证明身份质量；实际HTTP请求证明视觉服务接受并处理图片，不能证明其权重与配置声明相同；开发集R@3改善也不能代替独立`final test`。

> 技术审查建议：优先检查S02的候选池与分母、S03的冻结协议、S12的执行契约、S14的计时范围，以及S17/S18中保持为空的质量指标。它们决定了当前实现可作出的最强结论。